PROJET RÉALISÉ PAR

L'ÉQUIPE 5 DU GROUPE DE TD1

RAPPORT DE GROUPE DES DEEP LEARNERS ANONYMES
BASES DE DONNÉES + SCIENCES DES DONNÉES 2

Alban Gerschheimer, Omar Terras, Alfred Gyalay, Mia Portes.

Département MIASHS, UFR 6 Informatique, Mathématique et Statistique
Université Paul Valéry, Montpellier 3

Avril 2026

Soumis comme contribution partielle
pour le cours Science des données 2 et Bases de données

Déclaration de non plagiat

À compléter avant la remise du rapport.

Nous déclarons que ce rapport est le fruit de notre seul travail, à part lorsque cela est indiqué explicitement.

Nous acceptons que la personne évaluant ce rapport puisse, pour les besoins de cette évaluation :

- la reproduire et en fournir une copie à un autre membre de l'université ; et/ou,
- en communiquer une copie à un service en ligne de détection de plagiat (qui pourra en retenir une copie pour les besoins d'évaluation future).

Nous certifions que nous avons lu et compris les règles ci-dessus.

En signant cette déclaration, nous acceptons ce qui précède.

Signature : Marine Demangeot Date : 04/05/2025

Signature : Marine Demangeot Date : 04/05/2025

15 avril 2026

Remerciements

À compléter avant la remise du rapport.

Nos plus sincères remerciements vont à notre encadrant pédagogique pour les conseils avisés sur notre travail.

Nous remercions aussi ...

15 avril 2026

Résumé

L'image ci-dessous vous donne quelques conseils pour rédiger un bon résumé.

general background

specific background

knowledge gap

here we show...

results with key, concrete values

meaning of results

Horizontal gene transfer (HGT), the acquisition of genetic material from non-parental lineages, is known to be important in bacterial evolution[1,2]. In particular, HGT provides rapid access to genetic innovations, allowing traits such as virulence[3], antibiotic resistance[4] and xenobiotic metabolism[5] to spread through the human microbiome. Recent anecdotal studies providing snapshots of active gene flow on the human body have highlighted the need to determine the frequency of such recent transfers and the forces that govern these events[4,5]. Here we report the discovery and characterization of a vast, human-associated network of gene exchange, large enough to directly compare the principal forces shaping HGT. We show that this network of 10,770 unique, recently transferred (more than 99% nucleotide identity) genes found in 2,235 full bacterial genomes, is shaped principally by ecology rather than geography or phylogeny, with most gene exchange occurring between isolates from ecologically similar, but geographically separated, environments. For example, we observe 25-fold more HGT between human-associated bacteria than among ecologically diverse non-human isolates ($P = 3.0 \times 10^{-270}$). We show that within the human microbiome this ecological architecture continues across multiple spatial scales, functional classes and ecological niches with transfer further enriched among bacteria that inhabit the same body site, have the same oxygen tolerance or have the same ability to cause disease. This structure offers a window into the molecular traits that define ecological niches, insight that we use to uncover sources of antibiotic resistance and identify genes associated with the pathology of meningitis and other diseases.

All rights reserved by Nature. Reproduced here for educational purposes only.

The human body is a complex biological network comprising ten

Table des matières

Chapitre 1 Introduction 1
- 1.1 Introduction . . . 1
- 1.2 Responsabilités et composition de l'équipe . . . 1
- 1.3 Quelques détails techniques . . . 2

Chapitre 2 Base de données 4
- 2.1 Provenance des données . . . 4
- 2.2 Distance entre une observation et un port/plateforme . . . 4
- 2.3 Construction de classes de distance . . . 5
- 2.4 Descriptif des tables . . . 5
- 2.5 Modèles MCD et MOD . . . 5
- 2.6 Import des données . . . 6
- 2.7 Requêtes réalisées . . . 6
- 2.8 Quelques détails techniques . . . 6

Chapitre 3 Matériel et Méthodes 7
- 3.1 Logiciels . . . 7
- 3.2 Modélisation statistique . . . 7

Chapitre 4 Analyse Exploratoire des Données 8
- 4.1 Utiliser R . . . 8

Chapitre 5 Inférence statistique et modélisation 10
- 5.1 La droite de régression linéaire : un premier exemple . . . 10

Chapitre 6 Discussion 11

Chapitre 7 Conclusion et perspectives 12

Bibliographie 13

Annexes 14
- **Codes** . . . 14
- **Tables** . . . 14

Chapitre 1

Introduction

1.1 Introduction

La biodiversité marine est aujourd'hui soumise à de nombreuses pressions humaines, notamment liées aux activités portuaires et aux installations offshore. Les ports concentrent une forte activité maritime, logistique et industrielle, tandis que les infrastructures offshore modifient également les espaces marins. Il est donc pertinent de se poser la question suivante :

Dans quelle mesure la proximité des ports maritimes et des infrastructures offshore influence-t-elle la distribution spatiale des observations de biodiversité marine en Europe ?

Cette problématique s'appuie sur plusieurs sources de données réelles : des occurrences d'espèces marines issues de GBIF(mettre lien), des données géographiques sur les ports maritimes(mettre lien), ainsi que des données sur des infrastructures offshore(mettre lien).

L'objectif est de construire une base de données relationnelle permettant de croiser ces informations, puis de réaliser des requêtes SQL afin de dégager des tendances exploitables dans le cadre du cours de Sciences des données 2.

Le cadre du projet demande justement d'utiliser plusieurs sources réelles, de les intégrer dans une base relationnelle, puis de les interroger pour produire des tableaux et analyses.

Nous avons retenu ces jeux de données car ils permettent de croiser une information biologique, à savoir les occurrences d'espèces marines, avec des informations spatiales décrivant certaines pressions anthropiques. Ce croisement est cohérent avec notre problématique, qui porte sur l'influence potentielle des ports et des infrastructures offshore sur la distribution observée de la biodiversité marine.

1.2 Responsabilités et composition de l'équipe

Dans notre équipe, les taches ont été réparties de la manière suivante :

Alban Gerschheimer : Étudiant n°XXXX, Resp. de l'import de données et des requêtes SQL.
Omar Terras : Étudiant n°XXXX, Resp.
Alfred Gyalay : Étudiant n°XXXX, Resp. du code R.
Mia Portes : Étudiant n°22406297, Resp. du rapport.
....

1.3 Quelques détails techniques

Ortographe : Il est important de soigner l'orthographe. Vous devriez utiliser un correcteur en ligne tel que `languagetool`[1] (https://languagetool.org/fr).

R Markdown : Pour créer ce rapport, on vous demande d'utiliser `R Markdown`, via le logiciel `RStudio`.

Pour vous aider, on vous fournit un fichier `.Rmd` qui contient la structure du projet et qui présente quelques exemples de la syntaxe à utiliser. Vous pouvez donc partir de ce fichier et le modifier à votre guise. (Nous suggérons que vous organisiez votre rapport en utilisant des chapitres mais, en fonction de votre projet, rien ne vous empêche d'adopter une structure différente.)

La «compilation» (*i.e.*, «Kniter») du `Rmd` permet de créer soit un fichier PDF, soit un fichier Word, soit un fichier HTML (le PDF étant celui pour lequel les choses se passent le mieux, et aussi le format attendu pour ce cours).

Vous pouvez incorporer des *chunks* R qui seront exécutés à la volée. Vous pouvez inclure des commandes LaTeX.

Le désavantage de travailler avec un `.Rmd` sous `RStudio` est que vous travaillez en local : il faudra donc bien faire attention de prendre en compte les modifications de chacun.

Editeur collaboratif : Lorsque votre rapport sera proche de sa version finale, i.e. lorsqu'il ne restera que du texte à modifier, vous pourrez utilier le logiciel Overleaf (https://overleaf.com) pour collaborer avec les autres membres de votre équipe directement sur la version LaTeX de ce document (qui est un sous-produit créé quand vous cliquez sur Knit depuis RStudio).

Figure : Pour inclure une figure, il faut qu'elle ait une légende (ce qui est le cas pour la Figure 1.1 ci-après) et qu'elle soit référencée quelque part dans le document (ce qui est le cas dans les parenthèses qui précédent).

FIGURE 1.1: Une légende sous la figure.

Tableau : Notez que contrairement à une figure, la légende d'un tableau doit être mise **au-dessus** de celui-ci (*e.g.*, voir la Table 7.2 ci-dessous). Comme pour les figures, tout tableau doit également être discuté dans le texte du rapport.

Utiliser https://www.tablesgenerator.com/markdown_tables pour créer des tables Markdown simples, ou bien utiliser LaTeX. Plus de précisions sur l'utilisation des tableaux sont données en Annexe

1. Voir https://www.overleaf.com/blog/635-languagetool-a-free-browser-add-on-to-check-your-grammar-and-spelling et https://fr.overleaf.com/learn/how-to/Can_I_change_the_spell_check_language_to_e.g._Spanish%3F.

Les tables	sont	cool
col 1 est	alignée à gauche	$1600
col 2 est	centrée	$12
col 3 est	alignée à droite	$1

library(knitr)

```
install.packages("knitr")
library(knitr)
# Créer un tableau simple avec kable
df <- data.frame(Nom = c("Alice", "Bob"), Age = c(25, 30))
kable(df, format = "latex") # Peut aussi être "html", "latex"
```

Table : une légende au-dessus du tableau.

Nom	Âge	Ville
Alice	25	Paris
Bob	30	Lyon
Charlie	22	Marseille

Table 1.2: Exemple de tableau en LaTeX

Chapitre 2

Base de données

2.1 Provenance des données

Nous avons décidé de choisir des datas selon certains critères afin de garder une cohérence lors de cette recherche.

Les critères appliqués sont les suivants :

- zone : **Europe maritime**
- période : **2010–2026**
- espèces : **uniquement 3 grands groupes**
- observations : **présentes uniquement**
- coordonnées : **obligatoires**
- problèmes spatiaux : **exclusion des observations avec un problème géospatial**
- profondeur : **plus petit ou égal à 0**

METTRE IMAGES

Chaque observation d'espèce sera localisée à l'aide de ses coordonnées géographiques, puis comparée à la position des ports et des infrastructures offshore les plus proches. L'idée est que plus une observation est proche d'un port ou d'une infrastructure, plus elle est susceptible d'être soumise à une pression humaine potentielle. À l'inverse, les observations éloignées seront considérées comme situées dans des zones moins directement influencées.

2.2 Distance entre une observation et un port/plateforme

Pour chaque observation, nous calculerons la distance avec les ports maritimes présents dans notre base.
Si une observation a pour coordonnées (lat_o, lon_o) et un port (lat_p, lon_p), alors on calcule une distance géographique entre les deux points à l'aide de la formule suivante :

METTRE FORMULE

Cette formule donne une distance euclidienne simplifiée entre une observation o et un port p.

Ensuite, pour chaque observation, on garde seulement la distance au port **le plus proche**. On applique la même logique aux infrastructures offshore. Pour une observation o et une infrastructure i, la distance peut être notée :

METTRE FORMULE

Puis on retient la **distance minimale**.

2.3 Construction de classes de distance

Afin de rendre l'analyse plus lisible, les distances minimales calculées entre chaque observation et le port ou l'infrastructure offshore les plus proches n'ont pas seulement été conservées sous forme numérique. Elles ont aussi été transformées en classes de proximité, enregistrées dans les variables classe_distance_port et classe_distance_infra.

Dans notre codage, une valeur élevée correspond à une observation plus proche, tandis qu'une valeur faible correspond à une observation plus éloignée. Ce regroupement permet de comparer plus facilement la distribution des observations, le nombre d'espèces distinctes et la répartition des groupes taxonomiques selon le niveau de proximité aux ports et aux infrastructures offshore. Son echelle est de 1 à 10.

2.4 Descriptif des tables

Pour chaque table conservée, préciser le nombre de lignes et de colonnes après filtrage, lister les colonnes et donner pour chacune le type, la signification du champ et des caractéristiques (unique, clés, valeur manquante, ...) en remplissant le tableau ci-dessous.

TABLE 2.1: Espece (nombre de lignes × nombre de colonnes)

Nom colonne	Type	Signification	Caractéristique
id_espece	Texte	Identifiant unique de l'espece	Clé primaire, unique, non nul

2.5 Modèles MCD et MOD

— Pour le MCD, inclure une image réalisée avec le logiciel Mocodo [https://www.mocodo.net/] telle que celle visible sur la Figure 2.1 ci-dessous :

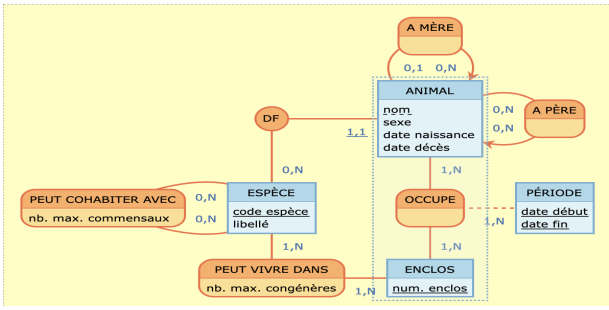

FIGURE 2.1: Relations.

— Pour le MOD, inclure une image réalisée avec le designer de phpmyadmin

Noter en passant qu'il est possible de créer des diagrammes en R Markdown au moyen du package `DiagrammeR` [https://rich-iannone.github.io/DiagrammeR/graphviz_and_mermaid.html] comme on peut le voir ci-dessous.

```r
# install.packages("webshot",dependencies = TRUE)
# library(webshot)
# webshot::install_phantomjs()
Sys.setenv(OPENSSL_CONF="/dev/null")
DiagrammeR::grViz("
digraph boxes_and_circles {

  # a 'graph' statement
  graph [overlap = true, fontsize = 10]

  # several 'node' statements
  node [shape = box,
        fontname = Helvetica]
  A; B; C; D; E; F

  node [shape = circle,
        fixedsize = true,
        width = 0.9] // sets as circles
  1; 2; 3; 4; 5; 6; 7; 8

  # several 'edge' statements
  A->1 B->2 B->3 B->4 C->A
  1->D E->A 2->4 1->5 1->F
  E->6 4->6 5->7 6->7 3->8
}
")
```

2.6 Import des données

- Préciser les nettoyages réalisés avant l'import comme l'uniformisation des valeurs des champs (*e.g.*, Mr, M., Monsieur, ...) ou le remplissage des valeurs manquantes par une valeur moyenne ...
- Source de données 1 :
  - Suppression des colonnes XXX, car XXX
  - Suppression des doublons dans les colonnes XXX
  - Filtrage en fonction de la colonne XXx, nous n'avons conservé que....

2.7 Requêtes réalisées

Pour chaque requête, l'exprimer en langage naturel puis en SQL. Puis donner le résultat obtenu (ou un extrait) et expliquer ce résultat.

L'objectif est de varier le type de requêtes et de répondre à votre problématique initiale.

2.8 Quelques détails techniques

On peut interagir avec une base de données directement depuis RMarkdown : i.e. requêter puis récupérer et afficher le résultat directement depuis le .Rmd. Un fichier connexionBDD.Rmd est fourni pour donner des exemples.

Chapitre 3

Matériel et Méthodes

3.1 Logiciels

Lister tous les logiciels utilisés pour la partie statistique du rapport (et également ceux pour gérer et communiquer entre les membres du projet s'il y en a en particulier)

R (ou Python) est le logiciel à privilégier pour la Science des Données. Pour assurer une reproductibilité maximale, vous devriez utiliser R Markdown (ou un Notebook Jupyter, et éventuellement un outil de gestion des versions tel que `Git`), par exemple via Google Colab ou RStudio dans les nuages. Évitez d'utiliser Word !

Il est de votre responsabilité de donner les versions des logiciels que vous utilisez, ainsi que de donner des informations techniques sur l'ordinateur qui vous a servi pour les analyses (système d'exploitation, vitesse du processeur, etc.). Penser à fournir des citations pour les logiciels utilisés, par exemple [1].

3.2 Modélisation statistique

Quels outils ou méthodes de statistiques allez-vous utiliser ? Donner des équations mathématiques s'il y a lieu et lister les éventuels présupposés («assumptions» en anglais) que vous devez faire sur les données afin d'utiliser ces outils ou méthodes (*e.g.*, normalité, absence de valeurs aberrantes, etc.).

Il est également bon d'indiquer quelles sont les avantages et les limites de ces méthodes.

Vous pourrez consulter avec profit les Chapitre 11–13 du livre sur R :
http://biostatisticien.eu/springeR/livreR.pdf

1. L'entrée BibTeX ajoutée dans le fichier `references.bib` a été obtenue grâce à la commande `citation(package = "tidyverse")` tapée dans la console de R.

Chapitre 4

Analyse Exploratoire des Données

Toute étude impliquant des données doit **obligatoirement** inclure une analyse exploratoire préalable. Celle-ci permet de mieux comprendre l'information contenue dans les données.

Il faut produire de nombreux résumés graphiques (*e.g.*, histogrammes, nuages de points, boxplots, etc.) et numériques (*e.g.*, médiane, moyenne, variance, etc.). Ainsi, il faut faire une analyse descriptive uni- et bivariée systématique de toutes les variables du jeu de données. Puis, il faut uniquement conserver les plus pertinents (les autres pouvant être gardés en Annexe), c'est-à-dire ceux qui permettront de dégager des éléments de réponse pour la question de recherche envisagée. Chaque figure et tableau doit être commenté. Mais il ne faut pas extrapoler et dire des choses qui ne sont pas visibles dans ces graphiques ou tableaux. Pour chaque analyse, vous pourrez préciser le nombre d'individus/ d'unités statistiques concernés au total.

Vous pourrez consulter avec profit le Chapitre 9 du livre sur R :
http://biostatisticien.eu/springeR/livreR.pdf

4.1 Utiliser R

Il est facile d'inclure des codes R dans votre rapport, qui seront exécutés à la volée (*i.e.*, lors de la traduction de votre fichier `Rmd` en fichier `PDF` ou `DOC`). Par exemple :

```
boxplot(cars, col = c("#5975a4", "#cc8963"))
```

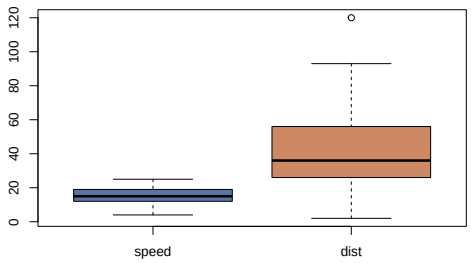

Figure 4.1: Deux boxplots.

```
colMeans(cars)
```

```
## speed  dist
## 15.40 42.98
```

Les lignes de code ne doivent pas dépasser dans la marge de droite. Ainsi on pourrait remplacer le chunk ci-dessous :

```
boxplot(cars, main = "Un titre qui est vraiment beaucoup trop long et qui dépas
```

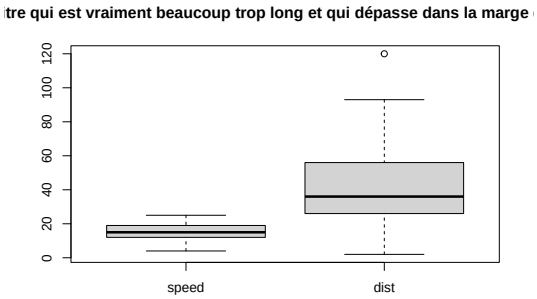

FIGURE 4.2: Pas super.

par celui-ci :

```
boxplot(cars,
        main = "Un titre qui est vraiment beaucoup trop long\n mais qui ne dépasse plus dans la marge de droite")
```

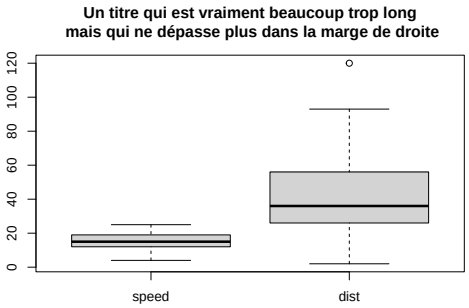

FIGURE 4.3: Déjà mieux.

où l'on a :

— utilisé la commande LaTeX `\tiny` pour changer la taille de la police (suivi de de `\normalsize` pour revenir à la taille normale),
— mis l'instruction `main = ...` sur la deuxième ligne,
— utilisé `\n` pour afficher le titre sur deux lignes.

Remarques : Contrairement aux graphiques précédents, nous vous demandons, pour effectuer les graphiques, d'utiliser le package `ggplot2`. Voir https://juba.github.io/tidyverse/08-ggplot2.html pour une courte introduction.

Chapitre 5

Inférence statistique et modélisation

Dans cette partie, vous pourrez utiliser les outils et méthodes vus au semestre précédent pour analyser les liens entre les variables.

Pour cela, vous pourrez utiliser les tests du χ^2, test du coefficient de corrélation linéaire, test d'Anova, la droite de régression linéaire.

Vous pourrez également proposer des modèles pour faire du clustering (k-means, CAH), de la classification (K plus proches voisins par exemple) comme vu en Science des données 1.

5.1 La droite de régression linéaire : un premier exemple

Si on souhaite expliquer les variations d'une variables réponse Y en fonction d'un certain nombre de prédicteurs $x_1, \ldots, x_p$, on peut utiliser un modèle de régression linéaire simple ($p = 1$) ou multiple ($p > 1$)

$$Y_i = \beta_0 + \beta_1 x_{1i} + \cdots + \beta_p x_{pi} + \epsilon_i, \qquad i = 1, \ldots, n.$$

où l'on présuppose que les ϵ_i sont i.i.d. $N(0, 1)$ pour tout $i = 1, \ldots, n$ (n étant la taille de l'échantillon).

Vous pourrez toujours consulter avec profit les Chapitre 11–13 du livre sur R :
http://biostatisticien.eu/springeR/livreR.pdf

Ces chapitres détaillent l'utilisation de certains tests et modèles sous `R`.

Chapitre 6

Discussion

Placer les résultats que vous avez obtenus dans le chapitre précédent en perspective par rapport au problème étudié.

Chapitre 7

Conclusion et perspectives

Quelles sont les conclusions principales ? Quelles sont vos recommandations pour le commanditaire ? Quelles analyses subséquentes pourraient être faites dans le futur ?

On attend de vous deux types de perspectives : des perspectives à court terme pour améliorer rapidement votre approche et des perspectives à plus long terme qu'elles soient liées à la science des données ou au domaine métier pour lequel vous avez travaillé.

Lister également les difficultés rencontrées dans la partie BD (e.g., taille de la base, manque de données, ...) et dans la partie statistique.

Bibliographie

Annexes

Il faut utiliser les annexes de façon judicieuse. C'est ici que l'on place des résultats trop volumineux pour apparaître dans le corps du rapport. Ou bien des résultats (e.g., graphiques) moins intéressants que les autres. Cela permet de limiter le nombre de pages du coeur du rapport, et d'ajouter des détails dans cette partie pour le lecteur désireux d'en savoir plus.

Codes

Ajouter vos codes informatique ici. Les codes doivent être correctement indentés et commentés.

Tables

Si vous avez des tableaux supplémentaires, vous pouvez les ajouter ici.

Utiliser https://www.tablesgenerator.com/markdown_tables pour créer des tables Markdown simples, ou bien utiliser LaTeX.

1. Table Markdown

Table 7.1: une légende au-dessus du tableau.

Les tables	sont	cool
col 1 est	alignée à gauche	$1600
col 2 est	centrée	$12
col 3 est	alignée à droite	$1

Aligner les nombres de la troisième colonne sur la droite permet d'afficher les unités au-dessus des unités, les dizaines au-dessus des dizaines, etc. Il faut toujours privilégier cette présentation.

2. Table Latex

Table 7.2: une légende au-dessus du tableau

Les tables	sont	cool
col 1 est	alignée à gauche	1600
col 2 est	centrée	12
col 3 est	alignée à droite	1

Remarques

— {lcr} : gauche (l), centré (c), droite (r)
— `\caption` place la légende au-dessus
— `\label` permet de référencer le tableau (`\ref{tab7.1}`)
— Les nombres sont bien alignés à droite dans la 3e colonne